Bitácora de trabajo — Proyecto 1

TFM de Data Science con IA · The Big School | Octubre de 2026

CIERRE TÉCNICO · 22/10/2026 — Previsión adicional de 61.720,70 £ y simulación de costes para los 45 días de prueba. Notebook principal: 01_analisis_exploratorio_completo.ipynb. Acceso del profesorado y envío al campus pendientes.

Versión definitiva del registro técnico personal: conserva datos, incidencias y motivos de las decisiones, sin repetir todas las celdas del notebook. Documento de apoyo para estudiar y defender el trabajo; no es una entrega obligatoria.

1. Objetivo y datos con los que empecé

Objetivo. Intenté predecir el importe comercial de la próxima jornada con transacciones para apoyar la planificación del negocio. No se trata de anticipar el beneficio, ni de una previsión de caja garantizada.

Fuente. Online Retail de UCI: archivo Online Retail.xlsx, 541.909 registros y 8 columnas. Incluye información de facturas, productos, cantidades, fechas y precios entre diciembre de 2010 y diciembre de 2011.

Primeras comprobaciones. Con Pandas revisé estructura, nulos, duplicados, fechas, cancelaciones y precios. Encontré 135.080 CustomerID vacíos, 1.454 descripciones ausentes y 5.268 filas idénticas. No eliminé filas automáticamente: CustomerID no era imprescindible para calcular ingresos diarios y las repeticiones podían ser líneas legítimas de una factura.

Un error que resolví. En una comprobación inicial anoté 365 jornadas con registros. Al auditar el calendario confirmé que eran 305 jornadas con registros dentro de 374 días naturales y 69 días sin movimientos. Lo dejé documentado y corregí el recuento. No puse esos 69 días a cero porque no podía asegurar que hubiera actividad comercial.

2. Cómo pasé de transacciones a ingresos

Al principio estudié ventas positivas, pero esa medida no reflejaba las cancelaciones y ajustes. Por eso inspeccioné los códigos de operaciones antes de decidir la variable objetivo.

Operaciones particulares. Conservé descuentos con código D y cancelaciones de cantidad negativa; excluí AMAZONFEE, BANK CHARGES y CRUK al interpretarlos como conceptos administrativos, no como actividad comercial ordinaria. Los códigos y supuestos están recogidos en el notebook.

Duplicados. La hipótesis de eliminar 5.226 líneas duplicadas reducía el importe bruto candidato en 24.573,74 £ (0,23 %). Decidí mantenerlas ante la falta de un identificador de línea que permitiera demostrar el error.

Caso excepcional. El 9 de diciembre de 2011 aparecía una línea positiva de 168.469,60 £ (80.995 unidades de PAPER CRAFT, LITTLE BIRDIE) y una cancelación equivalente unos doce minutos después. El último registro del dataset es a las 12:50; por posible jornada incompleta excluí esa fecha de la serie de modelado, no del historial documentado.

Resultado de preparación. Con las reglas definidas obtuve 539.305 líneas seleccionadas y 10.006.501,62 £ de ingreso comercial provisional, distribuidos en 305 jornadas. Tras apartar el último día, quedaron 304 jornadas para el experimento. Estos importes dependen de los criterios de clasificación: no son cuentas oficiales.

3. Variables y división temporal

Utilicé día de la semana, mes, ingresos de jornadas anteriores 1, 2 y 7, y la media de las siete jornadas previas. Las variables usan valores anteriores a la predicción. No representan necesariamente días naturales consecutivos.

Separación. Al eliminar los primeros 7 registros sin suficientes antecedentes, quedaron 297 observaciones: 207 de entrenamiento, 45 de validación y 45 de prueba, en orden cronológico. No mezclé fechas futuras con pasadas.

Matiz importante. Evalué predicciones de un solo paso: para cada jornada se disponía del histórico real observado hasta la anterior. Esto no prueba que el método funcione igual proyectando muchas jornadas futuras sin nuevas observaciones.

4. Comparación de modelos

Quise partir de referencias sencillas antes de probar Machine Learning. Comparé última jornada, media de siete, regresión lineal, Random Forest y una red neuronal MLP.

Modelo	MAE de validación (£)
Última jornada	19.191,79
Media de 7 jornadas	13.807,43
Regresión lineal	13.011,27
Random Forest	11.622,47
MLP	16.924,73

Qué observé. En validación Random Forest fue el mejor. La red MLP no logró converger dentro de las 2.000 iteraciones configuradas y no superó a las alternativas. No presento ese experimento como una red optimizada.

5. Qué me aportó la explicabilidad

Para Random Forest revisé importancia interna de variables, importancia por permutación y una explicación local con SHAP. Día de la semana y media reciente aparecieron entre las señales importantes. SHAP ayudó a entender una predicción concreta, aunque no demuestra causas de las ventas.

Esta parte permite responder por qué un modelo predice cierta cantidad, pero también obliga a recordar que entender sus predicciones no garantiza que generalice bien.

6. Prueba final y decisión

Conservé los datos de prueba para la evaluación final. Comparé solo Media 7 y Random Forest sin reajustarlos después según el resultado.

Modelo	MAE prueba (£)	RMSE prueba (£)
Media de 7 jornadas	14.015,88	18.744,80
Random Forest	18.924,47	23.767,55

La conclusión. Aunque Random Forest ganó en validación, en la prueba falló más. Elegí la media de siete jornadas como referencia operativa para este ejercicio. La sencillez y el resultado fuera del entrenamiento pesaron más que la complejidad.

Interpretación para negocio. Random Forest infraestimó 41 de 45 jornadas, frente a 23 de 45 con Media 7. Las sumas infraestimadas fueron 839.841,56 £ y 378.730,16 £, respectivamente. Son desviaciones de previsión, no pérdidas de dinero comprobadas; para calcular costes reales harían falta datos operativos y una función de costes.

7. Visualización en Tableau: qué falló y cómo lo corregí

Monté un dashboard con dos gráficos (evolución histórica y comparación de predicciones) y dos tarjetas con el MAE de cada modelo.

Fechas. Al principio el eje no mostraba correctamente el periodo porque la fecha estaba agregada de forma discreta. Cambié a día continuo para representar la secuencia temporal.

CSV. Tableau interpretaba ciertos importes como texto o nulos por la configuración regional. Exporté con separador punto y coma, coma decimal y codificación utf-8-sig.

Tarjetas MAE. Aparecía un total acumulado en lugar del error medio al usar SUMA; cambié el campo a PROMEDIO (PROM). También ajusté tamaño y espacio de las tarjetas para que las cifras no quedaran ocultas.

Resultado. El libro empaquetado TFM_Prediccion_Ingresos.twbx quedó en GitHub. Lo he descargado y abierto de nuevo; los gráficos y los indicadores se ven correctamente.

8. Notebook, README y repositorio GitHub

Preparé una versión académica del notebook con explicaciones Markdown, manteniendo el trabajo original. Ejecuté el notebook documentado en Colab y comprobé las cifras principales. Publiqué los notebooks, requirements.txt, el libro de Tableau y tres CSV: ingresos_tableau.csv, predicciones_tableau.csv y prediccion_siguiente_jornada.csv.

Problema al subir archivos. Al principio arrastré la carpeta principal completa y GitHub habría creado una carpeta duplicada. Luego costó colocar el TWBX en dashboard/: tuve

que crear la carpeta con .gitkeep y subir el archivo desde dentro. Repetí el procedimiento para resultados/.

README. Actualicé los apartados de dataset y licencia, comparación de modelos, métricas empresariales, arquitectura, dificultades y propuesta conceptual de despliegue. La fuente es UCI Online Retail (Chen, 2015). También incorporé el escenario hipotético de costes en la sección 8.2.

Entrega. El enunciado solicita dos repositorios GitHub separados y compartir sus enlaces en el campus; el Proyecto 1 pesa el 60 % de la nota. La bitácora es un apoyo personal y no se exige por sí sola.

9. ACTUALIZACIÓN FINAL — Predicción de la siguiente jornada

Por qué la añadí. Al revisar el cierre del proyecto me di cuenta de que habíamos evaluado predicciones sobre 45 jornadas históricas, pero no habíamos mostrado una estimación nueva posterior al periodo de modelado. Añadí una celda para demostrar ese último paso sin cambiar el entrenamiento ni las métricas de prueba.

Qué hice. Tomé las siete últimas jornadas con registros de la serie preparada, del 1 al 8 de diciembre de 2011, y calculé la media de sus ingresos comerciales. El resultado fue una previsión de 61.720,70 £ para la siguiente jornada con registros después del 8 de diciembre de 2011.

Cómo interpretarlo. Es una previsión histórica de un paso, no una predicción de ingresos actuales. No le asigné una fecha de calendario exacta, porque el conjunto no permite saber cuándo se registraría la siguiente actividad. Tampoco dispongo de un valor posterior fiable dentro de la serie de modelado para comprobar este nuevo importe.

Cómo lo dejé documentado. Añadí al notebook dos explicaciones Markdown alrededor del código, exporté prediccion_siguiente_jornada.csv y actualicé la sección 8.1 del README con el método, las siete observaciones, el resultado y las limitaciones. Probé de nuevo el notebook en un entorno de Colab limpio y confirmé los resultados principales.

10. Simulación de costes: pasar del error a un escenario de negocio

Por qué la añadí. Tras analizar el MAE y las cantidades infraestimadas y sobreestimadas, quise traducir esas diferencias a una situación de planificación empresarial. No contábamos con márgenes, inventarios ni costes reales de la empresa, por lo que opté por una simulación explícitamente hipotética.

Supuestos. Apliqué una penalización del 20 % a los ingresos infraestimados (posibles problemas de capacidad o existencias) y del 5 % a los sobreestimados (posibles recursos sobrantes). Estos porcentajes son elegidos para comparar escenarios, no estimaciones verificadas de pérdidas.

Cálculo. Coste simulado = 0,20 × suma de infraestimaciones + 0,05 × suma de sobreestimaciones. Partí de las desviaciones acumuladas de las 45 jornadas de prueba, que ya había calculado y documentado: Media 7, 378.730,16 £ por debajo y 251.984,62 £ por encima; Random Forest, 839.841,56 £ por debajo y 11.759,59 £ por encima.

Resultado. Media 7: 75.746,03 £ por infraestimación + 12.599,23 £ por sobreestimación = 88.345,26 £. Random Forest: 167.968,31 £ + 587,98 £ = 168.556,29 £. En este escenario Media 7 implica 80.211,03 £ menos de coste simulado.

Cómo lo documenté. Incorporé la sección 8.2 en el README y una celda de cálculo al final del notebook, cuyos importes comprobé en Colab. La celda usa las desviaciones acumuladas ya documentadas; para una trazabilidad más granular podría recalcularse el coste a partir de cada predicción individual.

Qué no demuestra. No son costes incurridos ni pérdidas reales. Con porcentajes distintos la comparación podría cambiar; antes de tomar decisiones harían falta datos operativos, márgenes y costes observados.

11. Qué enseñaría si me preguntan por el sistema en producción

Propondría un proceso por lotes al cierre de cada jornada registrada: actualizar operaciones, aplicar las mismas reglas, calcular la media de las siete jornadas anteriores, guardar predicción y revisarla cuando se conozca el dato real.

Monitorizaría MAE, RMSE, sesgo, incidencias de calidad y cambios en la distribución. La media móvil no se entrena; si se adoptase un modelo como Random Forest, habría que revisar periódicamente si merece reentrenamiento, versionando código y datos. Esto se plantea, no está implementado.

12. Estado actual y últimas comprobaciones

Trabajo	Situación
Notebook y métricas en Colab	Ejecutado por el alumno
Notebook y README en GitHub	README documentado; notebook principal renombrado a completo.ipynb
Dashboard TWBX descargado desde GitHub	Abierto correctamente en Tableau
Prueba de Colab desde un entorno nuevo	Realizada en entorno nuevo; resultados principales comprobados
Comprobación final de acceso del profesorado	Pendiente
Entrega de enlace por campus virtual	Pendiente

Para defenderlo debo poder explicar, sin leer, por qué mantuve posibles duplicados, por qué no imputé días a cero, por qué aparté la última jornada y por qué ganaba Media 7 en prueba. También tengo que tener claro que el error predictivo no es una pérdida económica real. Además, debo explicar por qué los costes simulados no son pérdidas reales.

Nota de trazabilidad: las cifras proceden del notebook, las salidas documentadas y el README. El notebook se ha vuelto a ejecutar desde un entorno nuevo de Google Colab y se comprobaron los resultados principales. Las comprobaciones de GitHub y Tableau se basan en las verificaciones realizadas durante el trabajo.